Атлас

Автоматическое заполнение характеристик товаров

Из названия, описания и параметров продавца получаем структурированные значения с подтверждением из исходного текста.

Сравниваем 4 подхода, чтобы выбрать экономичный вариант при нужном качестве.

Основной пользователь

Контент-менеджер товарного каталога

Проверяет предложения системы и готовит карточки к выгрузке.

Задача бизнеса

Сократить ручной перенос данных и исправление разнородных характеристик каталога.

Требования к результату

Разные входные данные

Название, описание и параметры продавца.
Партии CSV / JSON, описание в TXT
или обычный вставленный текст.

Проверяемое основание

Каждое извлечённое значение связано
с цитатой. Оценка модели помогает
назначить проверку, но не гарантирует ответ.

Схема зависит от категории

Бренд, модель и ключевые характеристики.
Единые названия, типы и единицы.
Результат включает оценку и источник.

Неопределённость сохраняется

Если данных нет, поле остаётся пустым.
Расхождения требуют решения человека.
Отклонение и отсутствие различаются.

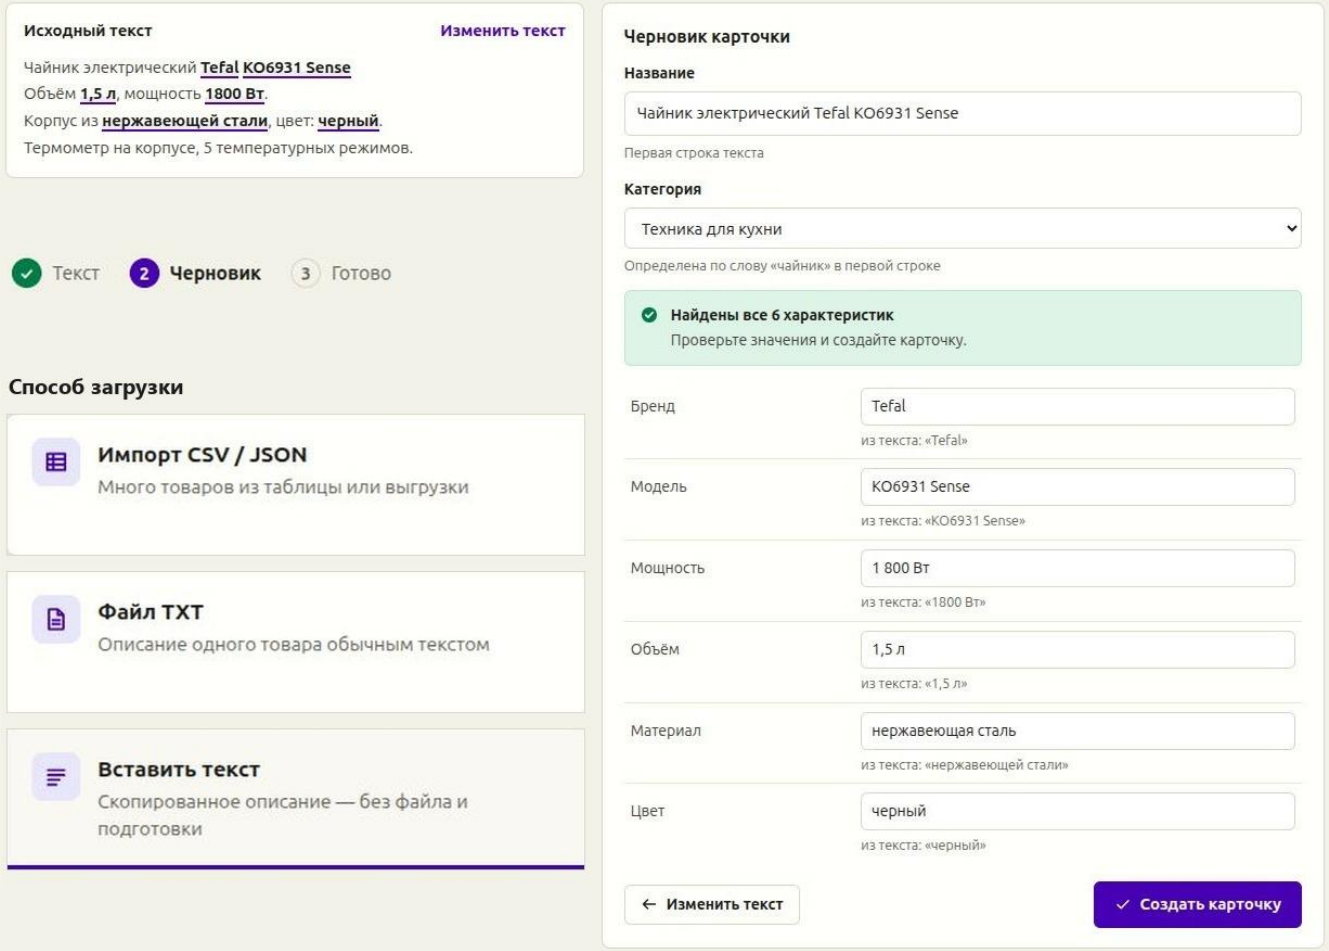
1. Приём данных

Партия товаров

Импорт CSV / JSON:
предпросмотр строк,
сопоставление колонок
и проверка ошибок.

Один товар

TXT или вставленный текст.
Система предлагает название,
категорию и характеристики.
Пользователь проверяет черновик.



Черновик по описанию. Название, категория и значения доступны для правки.

2. Сравнение четырёх подходов

Общий эксперимент: одни карточки, одна схема характеристик и единые правила оценки.

Подход	Что проверяем	Что входит в стоимость
Правила и словари	Шаблоны записи и известные значения	CPU, разработка и поддержка правил
NER на CRF	Извлечение по признакам слов и контексту	Разметка, обучение CRF и CPU
Трансформер	Извлечение с учётом контекста атрибута	Разметка, дообучение и инференс
LLM	Извлечение по инструкции и примерам	API-токены или локальные вычисления

Выберем метод или гибрид с минимальной полной стоимостью среди вариантов, которые проходят требования к качеству.

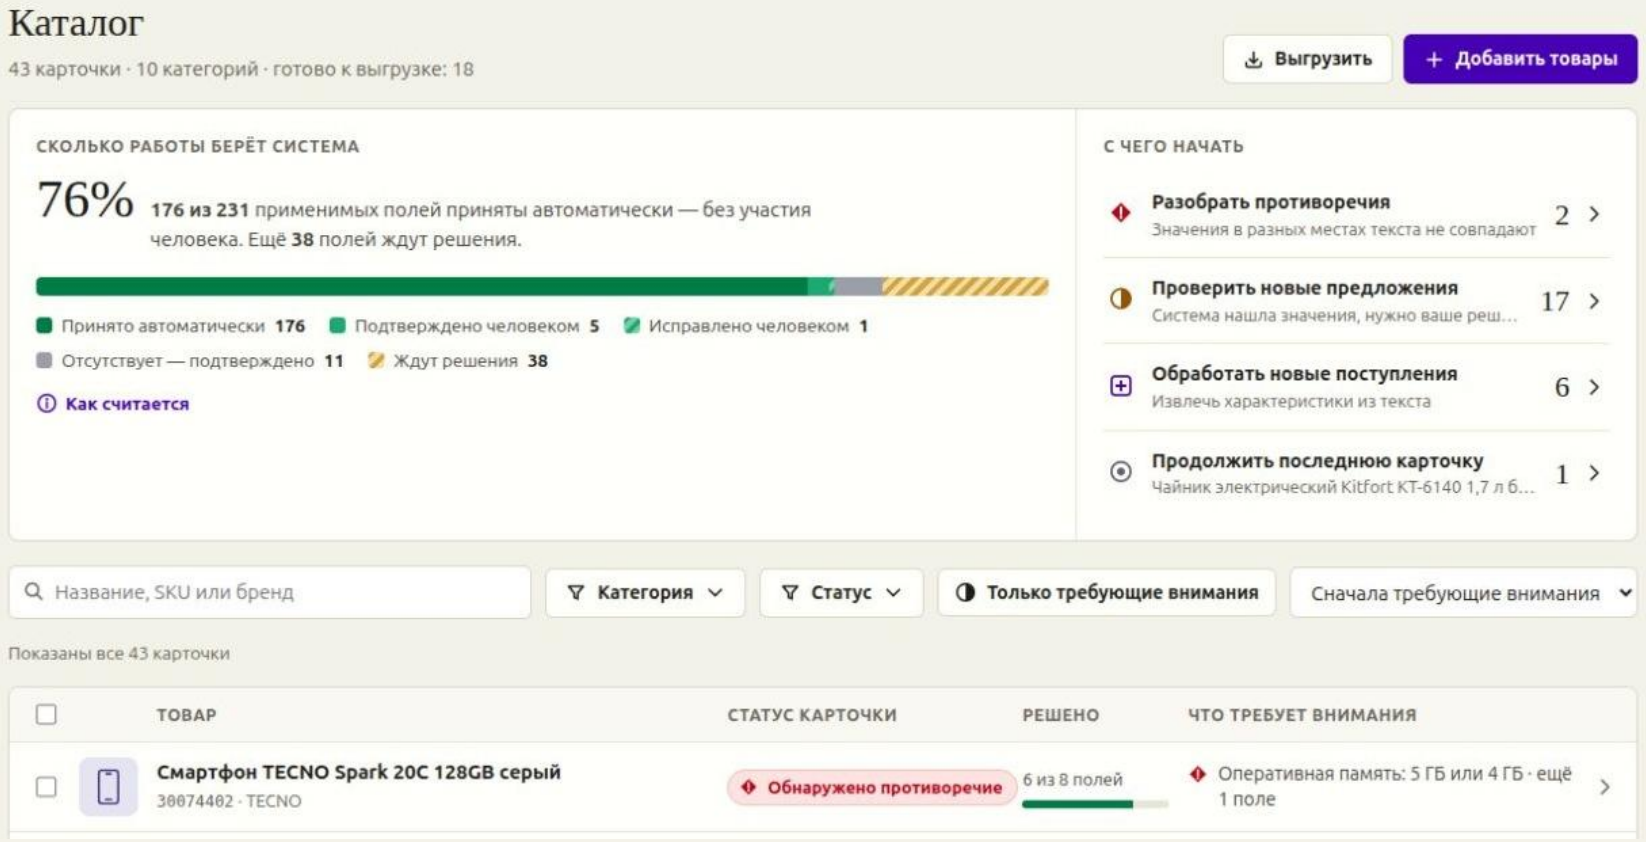
Отдельные оценки: трансформер silver span F1 около 0,917, правила с БЗ micro F1 около 0,925.
Протоколы различаются, общего победителя пока нет. LLM в разработке.

3. Каталог и очередь проверки

Понятный следующий шаг

Поиск по товару, бренду или артикулу. Фильтры по категории и состоянию карточки.

Сначала конфликты и спорные значения. Новые товары можно обрабатывать массово.



Показатели на экране иллюстрируют механику интерфейса.

4. Решение по цитате

В описании

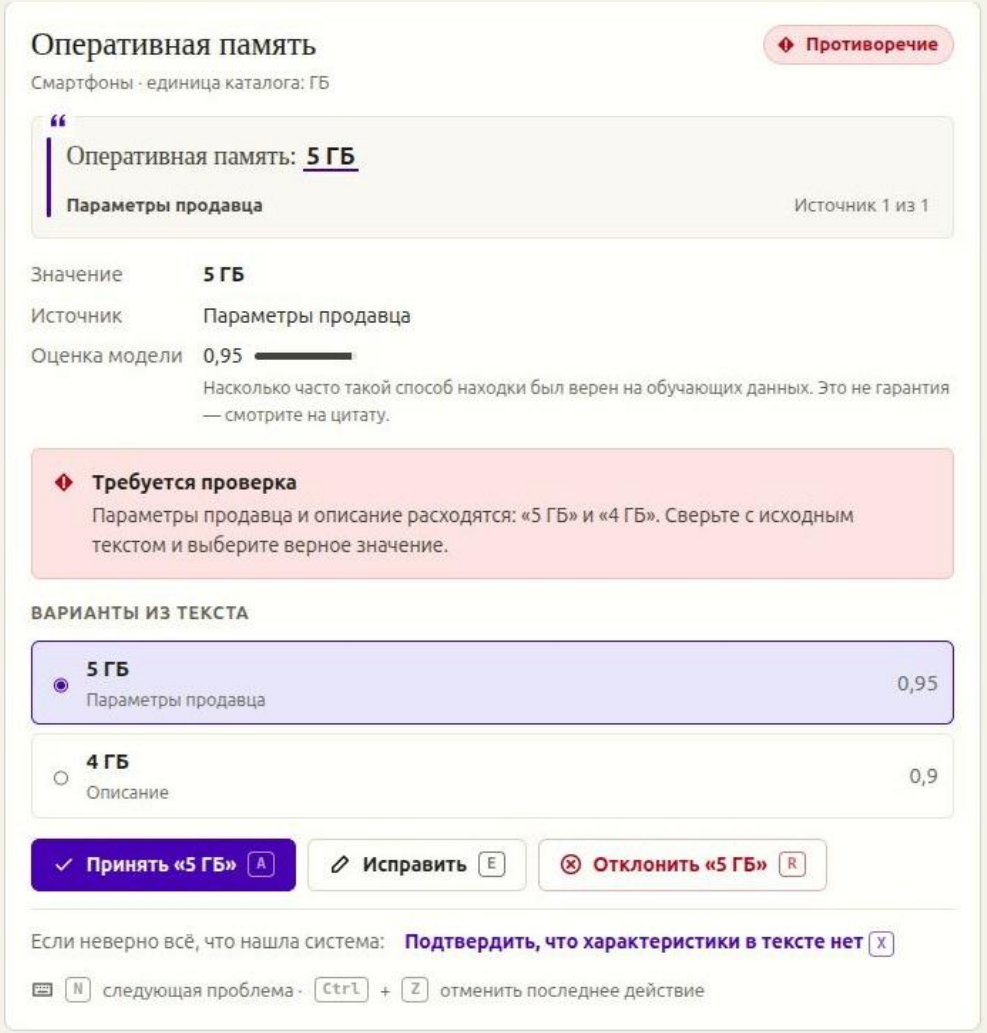
4 ГБ RAM

В параметрах продавца

5 ГБ RAM

Система показывает расхождение и оба основания. Сотрудник сверяет источники, затем принимает значение или вносит исправление.

Отклонить кандидата и подтвердить отсутствие характеристики в тексте можно отдельно.



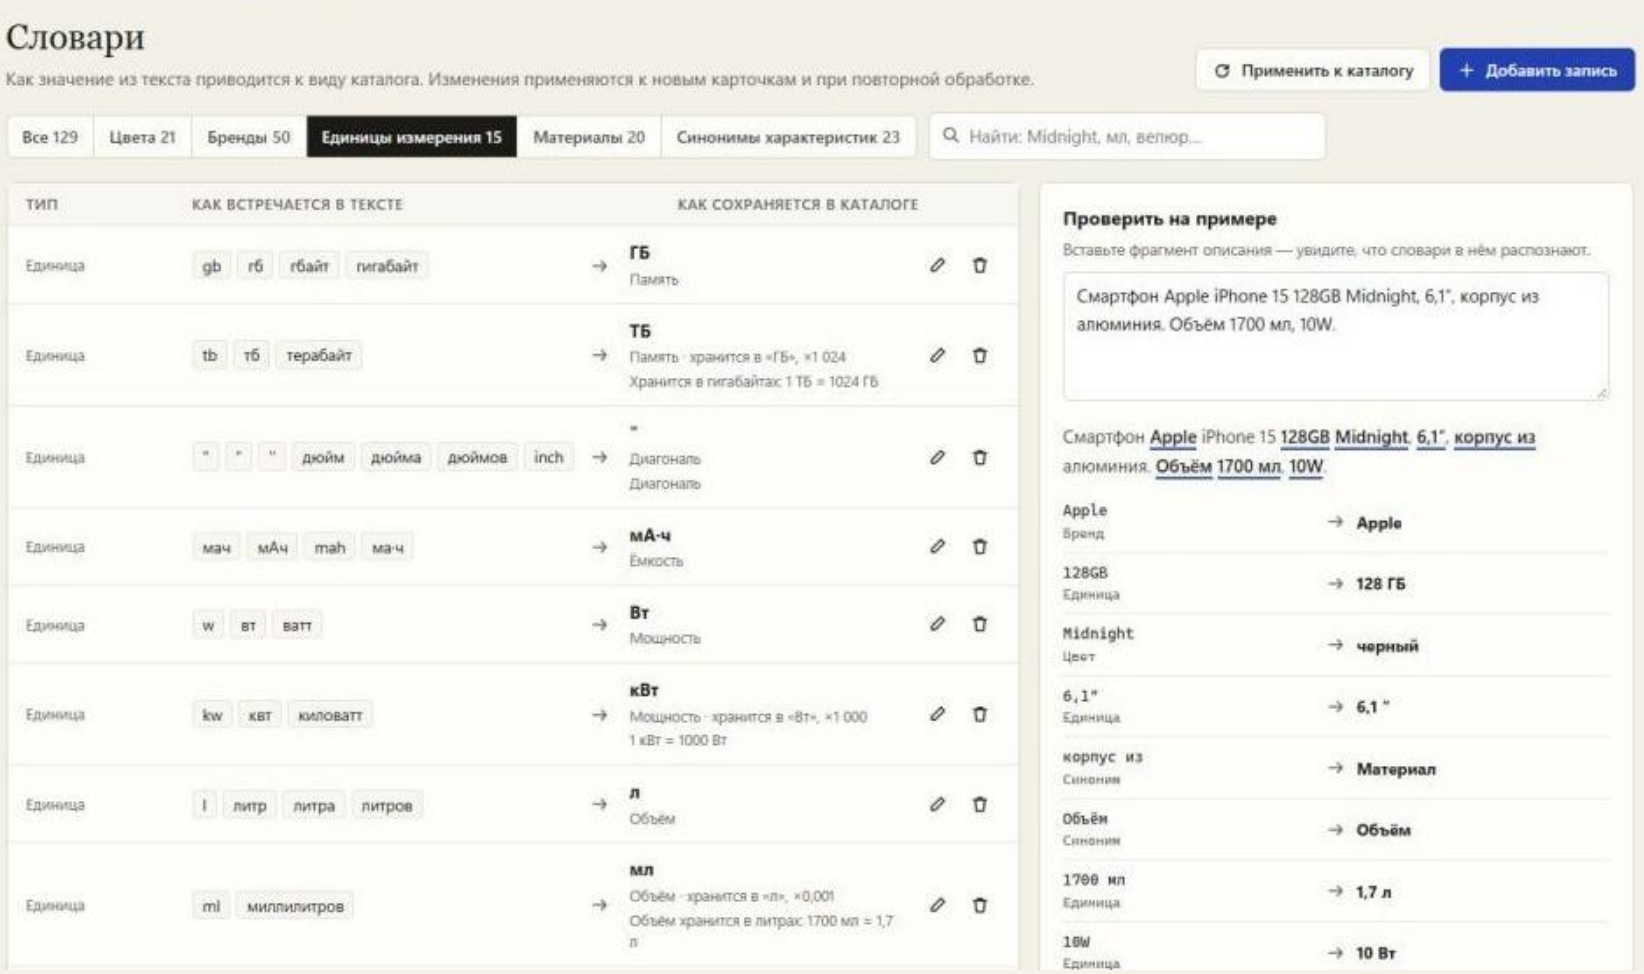
5. Нормализация значений

Одна единица каталога

«1700 мл»
1,7 л

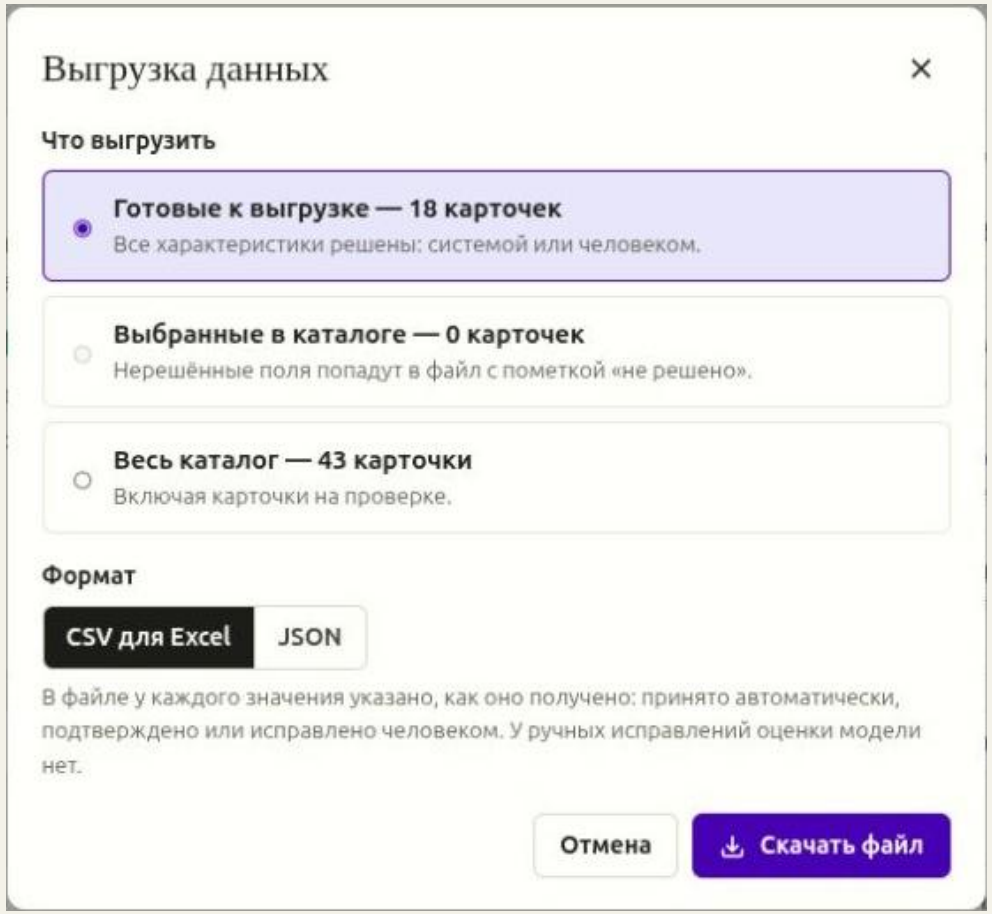
Словари объединяют варианты написания цветов, брендов и материалов.

Правило можно проверить на тексте перед применением.



Словарь единиц измерения и проверка распознавания на примере.

6. Выгрузка и контроль



Готовые карточки

CSV / JSON для дальнейшей загрузки в товарную систему. Для каждого значения сохраняется происхождение решения.

Контроль процесса

Аналитика показывает очередь, частые исправления и долю автоприёма. Ручная правка перестаёт считаться автоматическим решением.

Результаты проверки помогают выбирать категории для следующего улучшения.

Проверка вместо ручного ввода

Полный каталог обходится дешевле

Контент-менеджеру

Меньше ручного ввода. Значения предлагаются из текста, подтверждённые принимаются без участия человека.

Быстрая проверка. У каждого значения есть цитата и источник, описание не нужно перечитывать.

Только проблемные поля. Противоречия и сомнительные значения собраны в одной очереди.

Контроль. Любое автоматическое решение видно, объяснено и его можно отменить.

Бизнесу

Полнота. Больше товаров попадает в фильтры, поиск и сравнение.

Скорость вывода товара. Карточки от продавцов готовы без долгой ручной обработки.

Меньше ошибок. Система находит расхождения между текстом и уже заполненными значениями.

Дешёвое масштабирование. Основной поток идёт на обычных процессорах, дорогие модели только там, где окупаются.

Экономию времени измерим в пилоте.

Критерии выбора и успеха

Единый эталон с ручной проверкой, отдельный test и одинаковые правила оценки.

Показатель	Как проверяем
Качество	Micro F1 нормализованных пар и macro F1 по категориям
Надёжность автоприёма	Precision автоматически принятых значений
Автоматизация	Автоматически принятые поля / все применимые поля
Скорость	P50 / P95 обработки и время ручной проверки карточки
Полная стоимость	Стоимость за 1000 готовых карточек, включая вычисления и труд

Предлагаемый порог: precision автоприёма не ниже 98%.
Обучение и поддержку учитываем в стоимости на выбранном объёме каталога.

Выберем самый экономичный вариант, который проходит пороги качества и скорости.